

# 模式识别第一次作业

孙浩森 201928013229100

Email: sunhm15@gmail.com

## 1 问题一

a) 证明此规则下的误差概率为

$$P(error) = P(\omega_1) \int_{-\infty}^{\theta} p(x|\omega_1)dx + P(\omega_2) \int_{\theta}^{\infty} p(x|\omega_2)dx$$

证： 如果类别为  $\omega_1$ ，错误率

$$P(error|\omega_1) = \int_{-\infty}^{\theta} p(x|\omega_1)dx$$

如果类别为  $\omega_2$ ，错误率

$$P(error|\omega_2) = \int_{\theta}^{\infty} p(x|\omega_2)dx$$

因此，总的错误率

$$\begin{aligned} P(error) &= P(\omega_1)P(error|\omega_1) + P(\omega_2)P(error|\omega_2) \\ &= P(\omega_1) \int_{-\infty}^{\theta} p(x|\omega_1)dx + P(\omega_2) \int_{\theta}^{\infty} p(x|\omega_2)dx \end{aligned}$$

b) 通过微分运算，证明最小化  $P(error)$  的一个必要条件为  $\theta$  满足

$$p(\theta|\omega_1)P(\omega_1) = p(\theta|\omega_2)P(\omega_2)$$

证：  $P(error)$  最小化的必要条件为导数为 0，即

$$\frac{\partial P(error)}{\partial \theta} = P(\omega_1)p(\theta|\omega_1) - P(\omega_2)p(\theta|\omega_2) = 0$$

即，

$$p(\theta|\omega_1)P(\omega_1) = p(\theta|\omega_2)P(\omega_2)$$

c)  $\theta$  可以唯一确定吗？

解： 不能唯一确定，例如

$$\begin{aligned} p(x|\omega_1) &= 0.1 & x \in [0, 10] \\ p(x|\omega_2) &= 0.1 & x \in [5, 15] \\ P(\omega_1) &= P(\omega_2) \end{aligned}$$

则， $\forall \theta \in [5, 10]$  都满足上述式子。

d) 给出一个例子说明满足此时的一个  $\theta$  有可能使误差最大化。

解： 假设  $\omega_1, \omega_2$  满足

$$\begin{aligned} p(x|\omega_1) &= 1 - |x| & x \in [0, 10] \\ p(x|\omega_2) &= 2 - 4|x| & x \in [-0.5, 0.5] \\ P(\omega_1) &= P(\omega_2) \end{aligned}$$

由公式可以得出  $\theta = \pm \frac{1}{3}$ ，而

$$\begin{aligned} P(\text{error}|\theta = -\frac{1}{3}) &= \frac{25}{36} \\ P(\text{error}|\theta = \frac{1}{3}) &= \frac{5}{12} \end{aligned}$$

其中  $\theta = -\frac{1}{3}$  时，误差最大，而  $\theta = \frac{1}{3}$  时误差最小。

## 2 问题二

证： 决策风险可以显示如下，

$$C(\omega_j|x) = \begin{cases} \lambda_r & j = c+1 \\ \lambda_s(1 - P(\omega_j|x)) & j \neq i \end{cases}$$

因此，做出  $\omega_i$  决策的充分必要条件为

$$\begin{cases} \lambda_s(1 - P(\omega_j|x)) \geq \lambda_s(1 - P(\omega_i|x)) & \forall \omega_j \neq \omega_i \\ \lambda_s(1 - P(\omega_i|x)) \leq \lambda_r \end{cases}$$

即，

$$\begin{cases} P(\omega_j|x) \leq P(\omega_i|x) & \forall \omega_j \neq \omega_i \\ P(\omega_i|x) \geq 1 - \frac{\lambda_r}{\lambda_s} \end{cases}$$

如果  $\lambda_r = 0$ ，则  $C(\omega_{c+1}|x) = 0 < C(\omega_j|x)$ ，即始终做出决策为  $\omega_{c+1}$ ，如果  $\lambda_r > \lambda_s$ ，则  $C(\omega_{c+1}|x) = \lambda_r > \lambda_c > C(\omega_j|x)$ ，即不会做出  $\omega_{c+1}$  的决策。

### 3 问题三

a) 解释为什么作为先验概率  $P(\omega_1)$  函数的总贝叶斯风险一定要下凹?

证: 设  $\lambda_{ij} = \lambda(\alpha_i|\omega_j)$ ,  $R_i$  为分类器判断为  $\omega_i$  类别的决策区域, 则总贝叶斯风险可以表示如下,

$$R = \int_{R_1} [\lambda_{11}P(\omega_1)p(x|\omega_1) + \lambda_{12}P(\omega_2)p(x|\omega_2)]dx + \int_{R_2} [\lambda_{21}P(\omega_1)p(x|\omega_1) + \lambda_{22}P(\omega_2)p(x|\omega_2)]dx$$

将等式  $P(\omega_2) = 1 - P(\omega_1)$  和  $\int_{R_2} p(x|\omega_2)dx = 1 - \int_{R_1} p(x|\omega_2)dx$  带入并化简可以得到,

$$\begin{aligned} R = & \lambda_{22} + (\lambda_{12} - \lambda_{22}) \int_{R_1} p(x|\omega_2)dx \\ & + [(\lambda_{11} - \lambda_{22}) + (\lambda_{21} - \lambda_{11}) \int_{R_2} p(x|\omega_1)dx + (\lambda_{22} - \lambda_{12}) \int_{R_1} p(x|\omega_2)]P(\omega_1) \end{aligned}$$

可以看出, 对于任意的  $0 < P^*(\omega_1) < 1$ , 存在一个策略使得决策风险最小。而如果固定策略 ( $R_1, R_2$  固定不变) 时, 随着  $P(\omega_1)$  的不断变化, 总的贝叶斯风险显示一条过点  $(P^*(\omega_1), R(P^*(\omega_1)))$  的直线, 实际的贝叶斯曲线风险的曲线随着决策区域的改变, 一定会位于该直线的下方。

b) 利用极小化极大准则, 对于两个未知先验概率的一维正态分布进行决策

解: 对于 0-1 风险决策问题 ( $\lambda_{11} = \lambda_{22} = 0, \lambda_{12} = \lambda_{21} = 1$ ) 而言, 根据极大极小准则, 最优边界点需要满足,

$$\int_{R_1} p(x|\omega_2)dx = \int_{R_2} p(x|\omega_1)dx$$

将决策区域  $x^*$  代入得,

$$\int_{-\infty}^{x^*} p(x|\omega_2)dx = \int_{x^*}^{\infty} p(x|\omega_1)dx$$

因为两个类别的分布均为正态分布, 根据正态分布的性质, 上式可以等价于,

$$\frac{\mu_2 - x^*}{\sigma_2} = \frac{x^* - \mu_1}{\sigma_1}$$

化简可以得到分类平面为,

$$x^* = \frac{\sigma_1\mu_2 + \sigma_2\mu_1}{\sigma_1 + \sigma_2}$$

c) 求解问题 b 中对应的总贝叶斯风险。

解： 代入 a) 中的风险决策公式可以得到，

$$R = \int_{R_1} p(x|\omega_2) dx = \frac{1 - \operatorname{erf}\left[\frac{\mu_2\sigma_1 - \mu_1\sigma_2}{\sigma_1(\sigma_1 + \sigma_2)}\right]}{2}$$

d) 假设  $p(x|\omega_1) \sim N(0, 1), p(x|\omega_2) \sim N(0.5, 0.25)$ , 试求出  $x^*$  和总贝叶斯风险

解： 根据 b)、c) 两个问题的结果可以得出，

$$x^* = \frac{\sigma_1\mu_2 + \sigma_2\mu_1}{\sigma_1 + \sigma_2} = 0.4$$

$$R = \frac{1 - \operatorname{erf}\left[\frac{\mu_2\sigma_1 - \mu_1\sigma_2}{\sigma_1(\sigma_1 + \sigma_2)}\right]}{2} = \frac{1 - \operatorname{erf}(0.4)}{2} = 0.2858$$

## 4 问题四

a) 证明最小误差可以表示为

$$P_e = \frac{1}{\sqrt{2\pi}} \int_a^\infty e^{-\frac{\mu^2}{2}} d\mu$$

其中,  $a = \frac{|\mu_1 - \mu_2|}{2\sigma}$

证： 错误率表示如下：

$$P_e = P(\omega_1) \int_{-\infty}^{\theta} p(x|\omega_1) dx + P(\omega_2) \int_{\theta}^{\infty} p(x|\omega_2) dx$$

由于  $P(\omega_1) = P(\omega_2), \sigma_1 = \sigma_2$ , 分类边界为

$$x^* = \frac{\mu_1 + \mu_2}{2}$$

对应的错误率为：

$$P_e = \frac{1}{2} \left( \int_{-\infty}^{x^*} p(x|\omega_1) dx + \int_{x^*}^{\infty} p(x|\omega_2) dx \right) = \int_{x^*}^{\infty} p(x|\omega_2) dx = \frac{1}{\sqrt{2\pi}} \int_a^\infty e^{-\frac{\mu^2}{2}} d\mu$$

其中,

$$a = \frac{|x^* - \mu_1|}{\sigma_1} = \frac{|\mu_1 - \mu_2|}{2\sigma}$$

b) 利用不等式,

$$P_e = \frac{1}{\sqrt{2\pi}} \int_a^\infty e^{-\frac{\mu^2}{2}} d\mu \leq \frac{1}{\sqrt{2\pi}a} e^{-\frac{a^2}{2}}$$

证明随着  $\frac{\mu_1 - \mu_2}{\sigma}$  趋向于无穷,  $P_e$  趋近于 0

证：

$$\lim_{a \rightarrow \infty} P_e = \lim_{a \rightarrow \infty} \frac{1}{\sqrt{2\pi}} \int_a^\infty e^{-\frac{\mu^2}{2}} d\mu \leq \lim_{a \rightarrow \infty} \frac{1}{\sqrt{2\pi}a} e^{-\frac{a^2}{2}} = 0$$

## 5 问题五

a) 利用拉格朗日待定银子，推导合成的函数式

$$H_s = - \int p(x) [\ln p(x) - \sum_{k=0}^q \lambda_k b_k(x)] dx - \sum_{k=0}^q a_k$$

说明为什么对所有的  $x$ ，有  $a_0 = 1, b_0(x) = 1$  成立。

证： 由于概率密度的归一化条件，存在约束，

$$\int p(x) dx = 1$$

利用拉格朗日乘子，我们可以得到，

$$\begin{aligned} H_s &= - \int p(x) \ln p(x) dx + \lambda_0 [\int p(x) dx - 1] + \sum_{k=1}^q \lambda_k [\int b_k(x) p(x) dx - a_k] \\ &= - \int p(x) [\ln p(x) - \sum_{k=0}^q \lambda_k b_k(x)] dx - \sum_{k=0}^q a_k \lambda_k \end{aligned}$$

其中对于所有的  $x$  而言，有  $a_0 = b_0 = 1$ 。

b) 根据  $H_s$  对  $p(x)$  求导，证明最大熵分布遵循

$$p(x) = \exp[\sum_{k=0}^q \lambda_k b_k - 1]$$

证： 为了使得熵最小，需要使得熵的导数为 0，即

$$\frac{\partial H_s}{\partial p(x)} = - \int [\ln p(x) - \sum_{k=0}^q \lambda_k b_k + 1] dx = 0$$

积分号内值应该为 0，即

$$\ln p(x) = \sum_{k=0}^q \lambda_k b_k - 1$$

等价于

$$p(x) = \exp[\sum_{k=0}^q \lambda_k b_k - 1]$$

## 6 编程一

**编程环境** Python 3.7+numpy+random(python 自带)+matplotlib(画图)

**实验结果** 实验结果显示图1所示，其中均值、方差显示如下表1所示：




图 1 上机实验一结果图片对比

n	$\mu$	$\sigma$
1e4	10.44	49.40
1e5	-0.97	46.22
1e6	-1.27	47.91

表 1 上机实验一结果数据

根据实验结果可以看出，随着采样数目的增多，该分布近似于正态分布  $N(0, 50)$ 。

## 7 编程二

**编程环境** Python 3.7+numpy(内含多维高斯分布生成器)+random(python 自带)+matplotlib(画图)

**实验结果** 实验结果显示图2所示。




图 2 二维高斯采样

分类平面为

$$x_1 = 0$$

对应的错误率为: 0.13